

hep_COT

让大语言模型“读懂”一篇 HEP 实验论文 —— 把它压成一份结构化、可机读、可审计的分析报告

全文贯穿同一个真实例子: CMS VBF heavy Majorana neutrino search · **arXiv 2206.08956** · 13 TeV · 138 fb⁻¹ · same-sign $\mu\mu$

① 我们做了什么

输入一篇论文 → 产出一份结构化分析



② 六个物理问题

每张卡片下方是 teacher 在 arXiv 2206.08956 上的真实输出（节选）

Phase 1 测了什么

测量类型、终态、数据集、头条结果、图表家底、HEPData 可用性

measurement_type: 首次用 VBF 在 13 TeV 搜索重 Majorana ν 与 Weinberg operator 的同号双 μ 信号

final_state: 2 same-sign μ + VBF 双前向 jet 拓扑 + 丢失横动量

key_result: 观测 95% CL 上限，有效 $\mu\mu$ Majorana 质量 **10.8 GeV** (期望 12.8 GeV)

Phase 2 为什么做

理论动机、已有约束、相对前人的进步、是在回答谁的预言

theory_motivation: 中微子振荡提示 BSM; Weinberg dim-5 算符可生成 Majorana ν 质量并引入 LNV

BSM_or_SM_goal: BSM 搜索, type-I seesaw 下 m_N 从 50 GeV 到 25 TeV

comparison: 首次使用 VBF 通道, 互补于过去 DY/W 联合产生的搜索

Phase 3 怎么做

触发、对象定义、信号区、背景来源、估计方法、控制区

signal_regions: 按 m_N 分三档, 配不同判别变量

background: WZ、ZZ $\rightarrow$ 4 l 、ttZ、非 prompt 轻子、电荷误识

control_regions: 三个 CR 分别约束 WZ、ZZ、非 prompt

Phase 4 误差多大

主导系统误差、实验 vs 理论、关联处理、对结果影响

dominant: 信号/背景模板的统计误差 (Barlow-Beeston-lite) 最大

experimental: 亮度 1.2–2.5%、JES 2–5%、非 prompt 归一化 30%

theoretical: 理论 scale ~6%、PDF ~1%; 多年关联处理

Phase 5 统计与结论

拟合框架、观测量、中心值、置信区间、SM 一致性 · 此阶段强制补图表覆盖

framework: binned profile-likelihood + CL_s

observables: 各 SR 用 $p_T^{\mu 1}$ 或 H_T

sm_consistency: 观测与 SM 背景一致, 无显著超额

Phase 6 批判评估

优点、弱点、方法学启示、未来方向、可复现性

strengths: 首次 VBF 通道; $m_N \gtrsim 650$ GeV 当时 LHC 最强

weaknesses: 文中声称 HEPData 有记录但未检索到; 仅 $\mu\mu$

future: 加 ee / $e\mu$ 通道 + Run 3 延伸至更高 m_N

HEP 物理意义

把“读一篇 paper”这件事, 变成可比较的结构化数据。

- 一篇实验论文通读 + 做笔记 + 对 HEPData, 博士生要 2–3 天; 现在是一份六维 JSON, 每个数值都带 S/Fig/Table 出处
- 下游: 跨论文的系统误差对齐、限制对齐、方法学比较、自动化文献综述
- 为 HEP-ML、未来对撞机唯象提供结构化前置数据; 也给学生一份“不会漏系统误差、不会只抄摘要”的分析模板

AI 方法论意义

一个领域原生的推理评估 + 对齐基准。

- 常见 LLM benchmark 靠“GPT-4 当裁判”—— 主观、贵、不可复现
- 这里用论文天然的结构约束当裁判信号: **数值对上 · 引用对上 · 必填填满**
- 结果是可审计、可复现、无 **judge 漂移** 的对齐信号; 三路并行 (teacher / native / aligned) 同时度量裸能力与带反馈时的可教性

怎么测推理差距 & 怎么把弱模型对齐到强模型

关键点：反馈信号**不是**来自另一个 LLM，而是来自论文结构的规则化 diff

一条真实的反馈循环: **motivation** 阶段, student 第 1 轮漏掉 5 个数字 + 6 个引用锚点 → 收反馈 → 第 3 轮全部补齐

③ 三路并行实验 同一篇论文、同一套六维问题，只换"谁在读、带不带反馈"

STRAND 1 · REFERENCE

Teacher

OpenAI · GPT-5.4 (o-series, high reasoning)

强推理模型独立走完六维分析。

作用：给出参考答案。不当裁判。

STRAND 2 · BASELINE

Student — Native

DeepSeek V3.2-reasoner

弱推理模型独立作答，不看 teacher 结果。

作用：度量模型的裸能力基线。

STRAND 3 · ALIGNED

Student — Aligned

DeepSeek V3.2-reasoner + feedback loop

同一模型，每个维度最多 3 轮带反馈重试。

作用：度量模型的可教性 / 带反馈上限。

④ 反馈从哪来? — 不是另一个 LLM，是规则化 diff

三条确定性比对（无 LLM 参与）

对 Student 每一轮的回答，跟 Teacher 参考做三项比对；任一不过则把"缺什么"拼成反馈文本回塞，再来一轮，最多 3 轮。

RULE 1 · L1 numbers

关键数值是否对上

提取两边所有数字（含单位），按 5% 相对容差做集合匹配。

阈值：命中率 ≥ 0.80

RULE 2 · L1 citations

引用锚点是否对上

提取所有 \$/Fig/Table/HEPData/arXiv 标签，做集合交集。

阈值：命中率 ≥ 0.70

RULE 3 · L4 schema

必填字段是否填满

每个维度预先声明必须非空的字段（且不能是 "[uncertain]"）。

阈值：占比 ≥ 0.80

motivation 阶段 Round 1 的 diff 判决 · 来自 round5 实跑数据

L1 numbers · 命中 0.375 → 未达 0.80
missing: ["61", "165", "90%", "79", "180", (+3 more)]
L1 citations · 命中 0.182 → 未达 0.70
missing: ["arxiv:2009.06079", "arxiv:2012.09882", "fig:1", "sec_detector_and_simulation", "sec_intro_motivation", "arxiv:1605.02889"]
L4 schema · 6/6 字段非空 ✓ **pass**
tool-path · edit distance 7 to reference

塞回 student 下一轮 user prompt 的反馈文本 · 自动生成，逐字

[请重做 Phase `motivation`。第 2 轮]

裁判给出的差异摘要：

Numbers present in the reference but missing
from your answer: **61, 165, 90%, 79, 180** (+3 more)
Citations missing: arxiv:2009.06079,
arxiv:2012.09882, fig:1,
sec_detector_and_simulation,
sec_intro_motivation arxiv:1605.02889
Tool-call path differs from reference (edit distance 7).

修正建议：

- 请重新核对论文 / HEPData / 图表，给出具体数字（含单位与来源）
- 每个数值都要引用到具体的 \$/Fig/Table
- **不要盲目采纳假设的参考数值**
— 通过工具亲自在论文中验证。

结果： 反馈循环真的在推学生变细致

六个维度，Native → Aligned 的命中率变化 —— 引用 6/6 上升，数值 5/6 上升，一个真实 trade-off

motivation: 数值命中 0.38 → 0.75 (+0.37) · **syst**: 引用命中 0.33 → 1.00 (+0.67) · **stat_result**: 数值 0.17 → 0.75 (+0.58)

⑤ 数据全景 — 每行一个 phase，条形从中轴发散，直接读 Δ

Native → Aligned 的命中率 Δ

基线条宽 = Native 命中率的灰影；彩色条 = Δ。正向绿 / 蓝，负向品红。

■ Δ 数值（绿，正） ■ Δ 引用（蓝，正） ■ Δ 负向（品红）

坐标: $\Delta \in [-0.50, +0.70]$, 中轴 = 0

Δ 数值命中 · NATIVE → ALIGNED

Δ 引用命中 · NATIVE → ALIGNED

1. overview

0.78 → 0.56 /
0.25 → 0.75

0.78→0.56 -0.22

0.25→0.75 +0.50

2. motivation

0.38 → 0.75 /
0.18 → 0.59

0.38→0.75 +0.37

0.18→0.59 +0.41

3. strategy

0.39 → 0.77 /
0.33 → 0.67

0.39→0.77 +0.38

0.33→0.67 +0.34

4. syst

0.41 → 0.68 /
0.33 → 1.00

0.41→0.68 +0.27

0.33→1.00

5. stat_result

0.17 → 0.75 /
0.36 → 0.46

0.17→0.75

0.36→0.46 +0.10

6. assessment

0.00 → 0.57 /
0.57 → 0.86

0.00→0.57

0.57→0.86 +0.29

⑥ 一个 phase 的"之前 / 反馈 / 之后" — motivation 阶段 round1 答案 → 规则化 diff → round3 答案（真实节选）

BEFORE · Round 1 学生答案

motivation.short_answer

本文首次利用 VBF 过程在 LHC 上搜索重 Majorana 中微子和 Weinberg operator，目标是在质量 $m_N > 650$ GeV 时改善先前 LHC 限制，并首次在 collider 上测试 Weinberg operator。

~~<漏: "type-I seesaw" 的明确定位>~~
~~<漏: Majorana 质量头条数字 10.8 GeV>~~
~~<漏: KamLAND-Zen / Agostini 等 0vββ 先前约束>~~

FEEDBACK · 规则化 diff

auto-generated

Missing numbers (reference \ student):
61, 165, 90%, 79, 180

(KamLAND-Zen / Agostini 给出的
 $|m_{ee}|$ 90% CL 上限 meV 量级数字)

Missing citations:
arxiv:2009.06079, arxiv:2012.09882,
sec detector_and_simulation,
sec intro_motivation arxiv:1605.02889

Tool-call path edit distance: 7
(student 没查 intro_motivation 的
prior-constraint 参考)

→ 回塞 user prompt，下一轮重做

AFTER · Round 3 学生答案

same schema

本文首次利用 VBF 过程搜索
type-I seesaw 模型中的 heavy Majorana
neutrinos 和 Weinberg operator，在
 $m_N > 650$ GeV 区域给出了迄今 LHC 最
严格的 $|V_{\mu N}|^2$ 限制，并对 Weinberg
operator 给出了首个对撞机上的有效
 $\mu\mu$ Majorana 质量上限 10.8 GeV。

prior_constraints: KamLAND-Zen, Agostini
et al., $|m_{ee}|$ 90% CL 上限 61-165 meV
和 79-180 meV; NA62 带电 kaon LNV
衰变给 55 GeV 上限
(arxiv:1905.07770, § intro_motivation)。

⑦ 三条能带走的结论

Takeaway 1

"规则化 diff" 比 LLM judge 更有信息量

Takeaway 2

反馈循环大多数情况都在推学生变细致

Takeaway 3

看得见的 trade-off 才是有价值的

反馈里**精确到数字和锚点**（"漏了 61 meV、缺 arxiv:2009.06079"），而不是"写得不够全面"。学生能准确回去查对应 section，这是 LLM judge 做不到的。

12 个命中率指标里 **11 个上升**，其中 syst 的引用命中从 0.33 → 1.00、stat_result 的数值从 0.17 → 0.75。这说明 DeepSeek 的"带反馈时的可教性"比"裸能力"高出一大截。

唯一下降的 **overview 数值命中** (0.78 → 0.56) 是真实 trade-off: 学生为补回 "650 GeV / 23 TeV" 重写了答案、反而改掉了原本对的数字。LLM judge 会平均掉这个信号，规则化 diff 直接把它暴露出来。